Actividad 4. Spark ML

Pablo González Sánchez. Nº exp. 21938788 Grandes volúmenes de datos. Universidad Europea

1. Análisis de los datos

1.1. Preparación de los CSV

Los CSV proporcionados vienen con un formato distinto al que estamos acostumbrados, por eso hay que convertirlos a un dataframe especificando algunas características:

```
CSVanime = spark.read.option("quote", "\"").option("escape", "\"").csv('../dataset_valoraciones_anime/anime.csv', inferSchema=True, header=True)
```

Para asegurarme de que trabaja todo correctamente, he hecho una serie de comprobaciones:

```
print("Dos primeros nombres que contienen [,]:")
CSVanime.select("Name", "ID").filter(col("Name").like("%,%")).show(2, truncate=False)
print("Dos primeros nombres que contienen [']:")
CSVanime.select("Name", "ID").filter(col("Name").like("%'%")).show(2, truncate=False)
print("Dos primeros nombres que contienen [\"]:")
CSVanime.select("Name", "ID").filter(col("Name").like('%"%')).show(2, truncate=False)
print("Dos primeros nombres con caracteres japoneses:")
CSVanime.select("Japanese name", "ID").show(2, truncate=False)
```

1.2. Ítems mejor y peor valorados

Para ello, he agrupado los ratings por ítem, extrayendo la valoración media y la cantidad de ítems en el grupo. Luego, los uní al dataframe de animes para sacar su nombre. Para darle más sentido a esta clasificación, me quedé solo con aquellos ítems con al menos 50 ratings. El resultado son los primeros ítems ordenados por valoración media:

```
minValoraciones = 50
cantidadTop =
mejorMedia = CSVrating.groupBy("anime_id").agg(F.mean("rating"), F.count("rating"))
mejorMedia = mejorMedia.withColumnRenamed("avg(rating)", "average")
mejorMedia = mejorMedia.withColumnRenamed("count(rating)", "count")
juntar = CSVanime.select("ID", "Name")
mejorMedia = mejorMedia.join(juntar, CSVrating.anime_id==juntar.ID)
mejorMedia = mejorMedia.where(col("count") > minValoraciones)
mejorhedia = mejorhedia mejorhedia mejorhedia mejorhedia (con al menos", minValoraciones, "valoraciones):")
mejorMedia.sort("average", ascending-False).withColumnRenamed("count", "Nº ratings").drop("ID", "anime_i
                                                                                                             "anime id").show(cantidadTop, truncate=False)
print("Top", cantidadTop, "items con peor nota media (con al menos", minValoraciones, "valoraciones):")
mejorMedia.sort("average", ascending=True).withColumnRenamed("count", "Nº ratings").drop("ID", "anime_id").show(cantidadTop, truncate=False)
  Top 3 items con mayor nota media (con al menos 50 valoraciones):
                                                                                  Top 3 items con peor nota media (con al menos 50 valoraciones):
    -----+
                                                                                                        |Nº ratings|Name
  average
                     Nº ratings|Name
                                                                                    +-----
                                                                                |9.24564778301433 |20794 |Gintama°
  | 9.237009769219878 | 134197 | Fullmetal Alchemist: Brotherhood | | 9.224729815638906 | 9438 | Ginga Eiyuu Densetsu |
```

1.3. Valoraciones por género

La misma lógica seguí para obtener los géneros con mayores valoraciones, con una peculiaridad: Los géneros venían en una cadena de texto listándolos, así que primero tuve que convertir esa lista a un array, dividido por comas, eliminar los espacios, y luego con la función explode() dividir cada género en una fila independiente:

```
print("Géneros con mejor valoración media:")
CSVgeneros = CSVanime.select("Genres", "ID").filter(CSVanime.Genres != "Unknown")
CSVgeneros = CSVgeneros.join(CSVrating, CSVgeneros.ID==CSVrating.anime_id).drop("ID", "anime_id", "user_id")
CSVgeneros = CSVgeneros.select(split(col("Genres"), ","), "rating").withColumnRenamed("split(Genres, ,, -1)", "Genres")
CSVgeneros = CSVgeneros.select(explode(CSVgeneros.Genres), CSVgeneros.rating).withColumnRenamed("col", "Genero")
CSVgeneros = CSVgeneros.withColumn("Genero", trim(CSVgeneros.Genero))
{\tt CSVgeneros.groupBy("Genero").agg(F.mean("rating")).sort("avg(rating)", ascending=False).show(5)}
print("Géneros con peor valoración media:")
{\tt CSVgeneros.groupBy("Genero").agg(F.mean("rating")).sort("avg(rating)", \ ascending={\tt True}).show(5)}
 Géneros con mejor valoración media: Géneros con peor valoración media:
 | Genero| avg(rating)|
                                               | Genero| avg(rating)|
 +-----
                                             | Yaoi|6.0414369519964675|
| Hentai| 6.341275593904351|
  | Thriller|8.076588242745846|
     Samurai|7.935889107317298|
                                           | Yuri| 6.568662562954673|
| Kids|6.9025075230360144|
|Shoujo Ai| 7.065559471779689|
  |Historical|7.863716624096956|
 | Military|7.861498646075896|
| Police|7.835031637882817|
 +-----
                                              +-----
```

1.4. Estudios con mejor y peor nota

Del mismo modo, para los estudios mejor y peor valorados:

```
CSVestudios = CSVanime.select("Studios", "Score")

CSVestudios = CSVestudios.filter((CSVestudios.Score != "Unknown") & (CSVestudios.Studios != "Unknown"))

CSVestudios = CSVestudios.groupBy("Studios").agg(F.mean("Score"), F.count("Score"))

CSVestudios = CSVestudios.withColumnRenamed("avg(Score)", "Valoracion_media").withColumnRenamed("count(Score)", "Cantidad")

CSVestudios = CSVestudios.filter(CSVestudios.Cantidad >= 30).drop("Cantidad")

print("Estudios con peor valoración media (con al menos 30 valoraciones):")

CSVestudios.orderBy('Valoracion_media', ascending=True).show(5, truncate=False)

print("Estudios con mejor valoración media (con al menos 30 valoraciones):")

CSVestudios.orderBy('Valoracion_media', ascending=False).show(5, truncate=False)
```

2. Recomendaciones con SparkML

2.1. Construcción del dataframe

Para esta tarea hacen falta los tres dataframes, así que lo primero es unirlos. Primero, añadir el de ratings del usuario EP debajo del de ratings general (función union()). El de animes se une después según la columna anime_id. Luego renombré las columnas y eliminé las filas con datos sin completar

```
CSVml = CSVrating.union(CSVep).withColumnRenamed("rating", "User_rating")
CSVml = CSVmtaing.union(CSVep).withColumnémend("rating", "User_rating")

CSVml = CSVml,join(CSVmine, CSVml.anime_id=CSVmine.ID)

CSVml = CSVml.sine("c", "anime_id", "User_rating", "Genres", "name", "English name", "Type", "Episodes", "Studios", "Source", "Ranked", "Duration", "Popularity", "Score-10",

CSVml = CSVml.withColumn("anime_id"), cost("gilsh name"), "[gilsh name", "Type", "Episodes", "Studios", "Source", "Ranked", "Duration", "Popularity", "Score-10",

CSVml = CSVml.withColumn("anime_id"), cost("IntegerType()))

CSVml = CSVml.withColumn("anime_id"), cost("IntegerType()))

CSVml = durationNumber(CSVml)

CSVml = CSVml.bera(CSVml) | Source | "Usbrower", where (CSVml English name | ""Usbrower")
CSVml = CSVml.where(CSVml.Episodes != "Unknown").where(CSVml.English_name != "null").where(CSVml.English_name != "Unknown")
CSVml = CSVml.na.drop(subset=["Duration!", "Val_media"])
print("El dataframe tiene", CSVml.count(), "filas")
CSVml.printScheme()
CSVml.show(5)
 El dataframe tiene 46357218 filas
       -- user id: integer (nullable = true)
       -- user_id: integer (nullable = true)
-- anime_id: integer (nullable = true)
-- User_rating: double (nullable = true)
-- Genres: string (nullable = true)
-- name: string (nullable = true)
-- English_name: string (nullable = true)
   |-- English_name: string (nullable = true)
|-- Type: string (nullable = true)
|-- Episodes: string (nullable = true)
|-- Studios: string (nullable = true)
|-- Source: string (nullable = true)
|-- Ranked: string (nullable = true)
|-- Popularity: integer (nullable = true)
|-- Val_media: double (nullable = true)
|-- DurationN: double (nullable = true)
                                                                           ting Genres name English name Type Episodes Studios Source Ranked | P
9.0 | Military, Comedy,... | Fullmetal Alchemi... | Fullmetal Alchemi... | Movie | 1 | Bones | Manga | 1361.0 |
5.0 | Drama, Psychologi... | Kanojo to Kanojo ... | She and Her CatiT... | OVA | 1 | Unknown | Original | 2226.0 |
7.0 | Adventure, Histor... | Kaiketsu Zorro | The Magnificent Z... | TV | 52 | Ashi Production | Other | 2655.0 |
7.0 | Military, Police,... | Jin-Rou | Jin-Rob | The North | Movie | 1 | Production I.G | Manga | 846.0 |
8.0 | Adventure, Drama,... | Howl no Ugoku Shiro | Howl's Moving Castle | Movie | 1 | Studio Ghibli | Novel | 51.0 |
  |user_id|anime_id|User_rating| Genres|
+------
                                                                                                                                                                                                                                                                                                                                                   Studios| Source|Ranked|Popularity|
                                                                                                                                                                                                                                                                                                                                                                                                                                                                               Val media | DurationN |
                                                                                                                                                                                                                                                                                                                                                                                                                                              506 7.587968995355985
                                                                                                                                                                                                                                                                                                                                                                                                                                           1624 7.350737797956867 5104 7.227823867262285
                                                                                                                                                                                                                                                                                                                                                                                                                                         1181 7.796858984381786
                                                                                                                                                                                                                                                                                                                                                                                                                                               98 8.69212647198615
```

También pasé el dataframe por dos funciones que me construí, una para convertir la columna de duración a números (era cadena de texto sin ningún tipo de estándar) y otra para convertir las 10 columnas de valoraciones a una valoración media:

```
def valMedia(df):
    df = df.withColumn("Val_media", col("Score-10")*10*col("Score-9")*9*col("Score-8")*8*col("Score-7")*7*col("Score-6")*6*col("Score-5")*5*co
    df = df.withColumn("Val_media", col("Val_media")/(col("Score-1")*col("Score-2")*col("Score-3")*col("Score-4")*col("Score-6")*6*col("Score-6")*6*col("Score-6")*6*col("Score-6")*6*col("Score-6")*6*col("Score-6")*6*col("Score-6")*6*col("Score-6")*6*col("Score-6")*6*col("Score-6")*6*col("Score-6")*6*col("Score-6")*6*col("Score-6")*6*col("Score-6")*6*col("Score-6")*6*col("Score-6")*6*col("Score-6")*6*col("Score-6")*6*col("Score-6")*6*col("Score-6")*6*col("Score-2")*col("Score-2")*col("Score-2")*col("Score-4")*col("Score-6")*6*col("Score-6")*6*col("Score-2")*col("Score-2")*col("Score-4")*col("Score-6")*6*col("Score-2")*col("Score-2")*col("Score-6")*6*col("Score-6")*6*col("Score-2")*col("Score-2")*col("Score-6")*6*col("Score-6")*6*col("Score-2")*col("Score-2")*col("Score-2")*col("Score-2")*col("Score-4")*col("Score-6")*6*col("Score-2")*col("Score-2")*col("Score-2")*col("Score-2")*col("Score-2")*col("Score-2")*col("Score-2")*col("Score-2")*col("Score-2")*col("Score-2")*col("Score-2")*col("Score-2")*col("Score-2")*col("Score-2")*col("Score-2")*col("Score-2")*col("Score-2")*col("Score-4")*col("Score-4")*col("Score-4")*col("Score-4")*col("Score-4")*col("Score-2")*col("Score-4")*col("Score-4")*col("Score-4")*col("Score-4")*col("Score-4")*col("Score-4")*col("Score-4")*col("Score-4")*col("Score-2")*col("Score-4")*col("Score-4")*col("Score-4")*col("Score-4")*col("Score-5")*col("Score-4")*col("Score-6")*col("Score-6")*col("Score-6")*col("Score-6")*col("Score-6")*col("Score-6")*col("Score-6")*col("Score-6")*col("Score-6")*col("Score-6")*col("Score-6")*col("Score-6")*col("Score-6")*col("Score-6")*col("Score-6")*col("Score-6")*col("Score-6")*col("Score-6")*col("Score-6")*col("Score-6")*col("Score-6")*col("Score-6")*col("Score-6")*col("Score-6")*col("Score-6")*col("Score-6")*col("Score-6")*col("Score-6")*col("Score-6")*col("Score-6")*col("Score-6")*col("Score-6")*
```

NOTA: Los puntos 2.2, 2.3 y 2.4 se realizan dos veces, una para series y otra para películas. En este documento se ilustrará el proceso realizado para las series, pero el proceso para las películas es idéntico, salvo detalles explicados en los siguientes apartados.

2.2. Preparación de los datos

Del dataframe anterior, seleccioné sólo las filas cuya columna de tipo era "ONA" (siempre que el número de episodios fuese 2 o mayor) ó "TV". En el caso de las películas, simplemente seleccioné las que tuviesen como tipo "Movie". Luego, con la función StringIndexer pude asignarle un número a cada elemento de una columna de texto. Esto me permitió utilizar las columnas de géneros, tipo (en el caso de las series), estudios y source para el entrenamiento, ya que el algoritmo ALS sólo permite columnas numéricas.



2.3. Entrenamiento

Con los dataframe listos, lo último fue pasarlos por el algoritmo de recomendaciones de SparkML. Lo primero, lo dividí aleatoriamente en training (80%) y test (20%). Luego utilicé ALS para hacer las transformaciones y generar el modelo y las predicciones. Esto me devolvió las 5 mejores para cada usuario.

Para obtener las recomendaciones para el usuario EP, filtré los resultados por su id

Para asociar los ids resultantes, tuve que volver a unir los resultados con el dataframe de animes. Seleccionando las columnas que queríamos mostrar, y ordenando por valoración media como se pedía, obtuve los resultados finales:

```
EPpelisElegidas = EPpelis.where((col("anime_id") == 32890) | (col("anime_id") == 33533) | (col("anime_id") == 21129) | (col("anime_i
 EPpelisElegidas = EPpelisElegidas.dropDuplicates(["anime_id"])
EPpelisElegidas = EPpelisElegidas.select("anime_id", "User_rating", "name", "English_name", "Val_media")
EPpelisElegidas = EPpelisElegidas.sort("Val_media", ascending=False)
EPpelisElegidas.show(truncate=False)
   +-----+
 |anime id|User rating|name
                                                                                                                                                                                                                                                                                                                                                                                                        English name
                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                |Val media
 | 4621 | 7.0 | Arisubyeon-ui Kkumnamu | The Olympic Challenge | 6.19444444444445 | 32890 | 7.0 | Tu Xia Zhi Qing Li Chuanshuo | Legend of a Rabbit:The Martial of Fire | 5.745762711864407 | 21129 | 3.0 | Youtai Nuhai Zai Shanghai | A Jewish Girl in Shanghai | 5.621951219512195 | 37392 | 2.0 | Xi Yang Yang Yu Hui Tai Lang: Zhi Yang Nian Xi Yang Yang | Amazing Pleasant Goat | 5.159090909090909 | 33533 | 5.0 | Tokyo Onlypic | Tokyo Onlypic Pictures 2008 | 5.1351351351351351351
  EPseriesElegidas = EPseries.where((col("anime_id") == 3869) | (col("anime_id") == 8786) | (col("anime_id") == 14623) | (col("anime_id") == 19987) | (col("anime_i
 lanime id|name
                                                                                                                                                                               English name
                                                                                                                                                                                                                                                                                                                       Val media
 6.37037037037037
                                  | Chikyuu SOS Sore Ike Kororin | Do it Kororin Earth SOS | 5
```

NOTA: Este proceso no pude ejecutarlo localmente en mi ordenador, pues la cantidad de datos y de cómputos necesarios superaban las capacidades de mi portátil, así que este apartado tuve que hacerlo desde un clúster de Google Cloud

3. Representación gráfica con API Jikan

Para obtener información detallada de las series y películas resultantes, utilicé la API Jikan. Así, construí un array con los ids de los resultados y los recorrí en bucle, obteniendo la foto de portada, el nombre y la sinopsis, la duración y la cantidad de episodios.

Además, tuve que poner un pequeño delay a cada llamada a la API para que no me bloqueara por DoS:

```
peliculas = [4621, 32890, 21129, 37392, 33533]
series = [3869, 8786, 28145, 19987, 14623]
animes = [peliculas, series]
html code = ""
print("Recuperando información de la API", end="")
for tipos in animes:
   if(tipos == animes[0]):
       html_code += '<h1 style="text-align:center">Estas son las películas recomendadas para el usuario EP:</h1>'
   else:
       html_code += '<h1 style="text-align:center">Estas son las series recomendadas para el usuario EP:</h1>'
   for anime in tipos:
       api_url = "https://api.jikan.moe/v4/anime/"+str(anime)+"/full"
       response = requests.get(api_url).json()
       nombre = response["data"]["titles"][0]["title"]
       if(response["data"]["synopsis"] == None):
           sinopsis = "No se ha encontrado sinopsis para esta serie"
           sinopsis = response["data"]["synopsis"]
        imagen = response["data"]["images"]["jpg"]["image_url"]
        if(tipos == series):
           episodiosHTML = "<b>Episodios de la serie: </b>"+str(response['data']['episodes'])+""
           episodiosHTML = ""
        duracion = response["data"]["duration"]
       generos_ = response["data"]["genres"]
generos = ""
       for genero in generos_:
          generos += genero["name"] + ", "
        generos = generos[:len(generos)-2]
        if(generos == ""):
           generos = "No se han encontrado géneros para este anime aún"
       html_code += '''
       <div style="display:flex;border:1px solid black;padding:10px;width:75%;margin:auto;margin-bottom:10px;">
```

Para representar esto gráficamente, utilicé una cadena de texto con código HTML, pero con la información mediante variables de python:

Recuperando información de la API.....

Estas son las películas recomendadas para el usuario EP:



Nombre: Arisubyeon-ui Kkumnamu

Sinopsis

This is a story of a 13 year old girl whose only dream is to participate in the Olympic Games: Her Struggles, her victories, her failures and her willpower fascinate all who help her to become a outstanding athlete.

Duración: 1 hr 15 min Géneros: Drama, Sports



Nombre: Tu Xia Zhi Qing Li Chuanshuo

Sinopsis:

Sequel to the movie Legend of a Rabbit It's been couples of years since Tu defeated Slash. More than a hero, Tu is regarded as the protector of the village defeating bandits and upholding justice. However, with no real foundation in Kung Fu, Tu has to start from zero in order to harness the Kung Fu skills which he inherited from the Grandmaster. One day, Tu rescues an old injured warrior who finally turns out to be the evil Zhan. Zhan plans to take over the world of Martial Art by acquiring a precious gem from the real successor Lan of Huo Clan. Upon confrontation. Tu fails to save Lan and the Martial of Fire. The reality hits him and Tu realizes he's just a lucky rabbit who happens to inherit the Grandmaster's Kung Fu. Therefore, Tu restarts to practicing Kung Fu as much encouragement from Penny and Biggie. As time goes by, Tu's able to get on his feet and join his fellow warriors, Penny and Biggie, to stop Zhan's evil plan, while Zhan is getting closer to his goal. Finally, Tu defeats against evil Zhan by holding the True Harmony of the Martial of Fire & Water. (Source: GSC Movies)

Duración: 1 hr 35 min

Géneros: Action, Adventure, Comedy



Nombre: Youtai Nuhai Zai Shanghai

Sinopsis:

Set mainly in and around the Shanghai Ghetto in Japanese-occupied Shanghai during the Second World War, the film tells the story of three children. Rina and her younger brother Mishalli are Jewish refugees who escaped Europe but are without their parents. A-Gen is a Chinese boy who meets Rina and helps her and her brother to survive. The children form strong friendships and have adventures as they try and fend off the Japanese army occupying the city, and their allies, the Nazis. In the background, the Second Sino-Japanese War takes place, while the children must face the uncertainty that concerns the fate of Rina and Mishalli's parents in Europe. (Source: AniDB)

Duración: 1 hr 19 mir

Géneros: No se han encontrado géneros para este anime aún



Nombre: Xi Yangyang Yu Hui Tailang: Yang Nian Xi Yangyang

Sinopsis:

In Green Green Pastures, there exists a much loved legend about valiant dragon-slayers who lived in the Stone Age. Having grown up listening to stories about their awe-inspiring adventures, Pleasant Goat and Fatty Goat have always wanted to become dragon slayers themselves. While trying to make this dream come true, Fatty Goat inadvertently switches bodies with Big Big Wolf, and the two, along with Pleasant Goat, soon find themselves transported back to the Stone Age. When an evil dragon appears and threatens Stone Age Green Green Pastures, Fatty Goat, Big Big Wolf and Pleasant Goat must rise up to the dragon-slaying challenge. (Source: YesAsia)

Duración: 1 hr 26 min

Géneros: Adventure, Comedy



Nombre: Tokyo Onlypic

Sinopsis:

An omnibus film depicting 15 fictional sports events created by different directors. Onlypic stands for only + pictures (video).

Duración: 2 hr 47 min

Géneros: Comedy, Sports





Nombre: Sakura Momoko Gekijou: Coji-Coji

Sinopsis:

The only thing that concerns Coji Coji is enjoying life and the wonders of nature. Coji Coji's friends, on the other hand, are a varied bunch of colorful characters whose many idiosyncrasies have a tendency to create turmoil among one another. Coji Coji's carefree ways and tendency to shirk responsibility are sometimes a source of frustration, but his childlike wisdom has a way of resolving all of their differences. (Source: AniDB)

Episodios de la serie: 100

Duración: 25 min per ep

Géneros: Comedy, Fantasy



Nombre: Inakappe Taishou

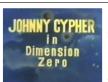
Sinopsis:

A comedy about a country boy that travels to the city to study judo. He ends up meeting the daughter of a prominent dojo and her judo skilled cat. Each episode features 2 stories. (Source: AniDB)

Episodios de la serie: 104

Duración: 24 min per ep

Géneros: Comedy, Sports



Nombre: Johnny Cypher

Sinopsis:

Square-jawed superagent Johnny can travel through inner space, Dimension Zero, and uses his superpowers to combat evil all over the universe. He is helped by the beautiful blonde Zena and tiny alien Rhom from the Black Star. An early Japanse-American co-production by former Disney animator Joe Oriolo for Warner/Seven--a company formed by the merging of Seven Arts production after its merger with Warner Bros. It started airing a year after its release in the US. (Source: The Anime Encyclopedia)

Episodios de la serie: 130

Duración: 5 min per ep

Géneros: Action, Adventure, Sci-Fi



Nombre: Kaitou Pride

Sinopsis:

Each episode features a part of the story in which a detective tries to hunt down and capture a notorious and narcissistic thief. This series aired daily, Monday to Friday, in 8 minutes segments to complete a single story by the end of the week. (Source: AniDB)

Episodios de la serie: 105

Duración: 8 min per ep

Géneros: Adventure, Comedy



Nombre: Chikyuu SOS Sore Ike Kororin

Sinopsis:

Jiang came to the old family cherry blossom viewing venue. But the surrounding area was full of garbage. He sits there to eat lunch reluctantly when a strange creature falls from the sky! Kororin is his name. He comes from the Star Oasis and is here to teach the importance of environmental consciousness with his ESP. Jiang, his sister, and Kororin must battle Syndrome, the evil alien plotting the destruction of the Earth. The attempted destruction is usually through some environmental issue such as tearing a hole in the ozone, or changing the weather, or overuse of electricity, etc.

Episodios de la serie: 26

Duración: 25 min per ep

Géneros: Action, Comedy, Sci-Fi